

Отчёт о выполнении лабораторной работы №1

«Поиск частых наборов объектов (алгоритм Apriori)»

Дисциплина: Основы интеллектуального анализа данных

Выполнил: Andrey Zamyatin, группа ET-442, ЮУрГУ

1. Формулировка задания

Разработать программу, выполняющую поиск частых наборов объектов в заданном наборе данных с помощью алгоритма Apriori (или одной из его модификаций). Список результирующих наборов должен содержать сами наборы и значение поддержки для каждого набора. Параметрами программы являются набор данных, порог поддержки и способ упорядочивания результирующего списка наборов (по убыванию значения поддержки или лексикографическое).

Требуется провести эксперименты на наборе данных `baskets.csv` (сведения о покупках в супермаркете), варьируя пороговое значение поддержки (1%, 3%, 5%, 10%, 15%), и визуализировать результаты в виде двух диаграмм:

- 1) сравнение быстродействия алгоритма на фиксированном наборе данных при изменяемом пороге поддержки;
- 2) количество частых наборов объектов различной длины на фиксированном наборе данных при изменяемом пороге поддержки.

2. Репозиторий с исходными материалами

Исходный код, набор данных и остальные материалы лабораторной работы лежат в каталоге `lab1` репозитория на GitHub: https://github.com/Trenj/data_mining/tree/main/lab1.

Состав каталога `lab1`:

- `apriori_market_basket.ipynb` — реализация алгоритма Apriori, проведение экспериментов и построение графиков
- `baskets.csv` — исходный набор данных о покупках (7501 транзакция, 115 уникальных товаров, кодировка `cp1251`)
- `runtime_vs_support.png` — график зависимости времени выполнения от порога поддержки
- `itemset_counts_by_length.png` — график количества частых наборов разной длины от порога поддержки
- `Task.txt` — текст задания

2.1. Краткое описание реализации

Алгоритм Apriori реализован с нуля на Python, без сторонних библиотек для самого поиска частых наборов. Функция `apriori(transactions, min_support, sort_by)` принимает список транзакций, порог поддержки (доля от 0 до 1) и способ сортировки результата ("`support_desc`" — по убыванию поддержки, "`lexicographic`" — лексикографически), а возвращает список пар (набор объектов, значение поддержки). Код разбит на несколько функций:

- `get_frequent_items` — находит частые наборы, состоящие из одного товара;

- `generate_candidates` — строит кандидатов следующего размера, отбрасывая тех, у кого есть нечастое подмножество (это и есть свойство антимонотонности поддержки, на котором строится Apriori);
 - `count_support` — считает поддержку кандидатов по всем транзакциям;
- основной цикл повторяет генерацию кандидатов и подсчёт поддержки, пока находятся новые частые наборы.

2.2. Проверка корректности (порог 10%)

На пороге поддержки 10% алгоритм находит 7 частых наборов, все длины 1. Ниже — результат в обоих режимах сортировки: набор данных один и тот же, различается только порядок.

По убыванию поддержки	Лексикографически
минеральная вода — 0.2384	зеленый чай — 0.1321
макароны — 0.1880	картофель-фри — 0.1709
яйца — 0.1797	макароны — 0.1880
картофель-фри — 0.1709	минеральная вода — 0.2384
шоколад — 0.1638	молоко — 0.1296
зеленый чай — 0.1321	шоколад — 0.1638
молоко — 0.1296	яйца — 0.1797

3. Результаты экспериментов

Эксперименты проведены на наборе данных `baskets.csv` (7501 транзакция, 115 уникальных товаров, средняя длина транзакции 3.91 товара) при пороге поддержки 1%, 3%, 5%, 10% и 15%. Для каждого порога измерено время работы алгоритма и число найденных частых наборов в разбивке по длине. Сводные результаты — в таблице ниже.

Порог, %	Всего наборов	Время, с	длина 1	длина 2	длина 3	длина 4	длина 5
1	261	9.944	74	170	17	0	0
3	55	1.099	36	19	0	0	0
5	28	0.460	25	3	0	0	0
10	7	0.048	7	0	0	0	0
15	5	0.030	5	0	0	0	0

3.1. Быстродействие алгоритма




Рисунок 1 — время выполнения Apriori на baskets.csv в зависимости от порога поддержки

3.2. Количество частых наборов по длине




Рисунок 2 — количество частых наборов объектов разной длины в зависимости от порога поддержки

4. Анализ и выводы

С понижением порога поддержки количество найденных частых наборов резко растёт: с 5 наборов при пороге 15% до 261 набора при пороге 1%. Основной вклад в этот рост дают наборы длины 2 и 3 — при порогах 10% и 15% в результат попадают только отдельные товары, а при более низких порогах (1-5%) уже видны совместные покупки пар товаров, а при пороге 1% — и троек.

Время выполнения растёт вместе с числом наборов: с 0.03 с при пороге 15% до почти 10 с при пороге 1%. Причина в том, что при низком пороге частыми на первом шаге

оказывается больше отдельных товаров, из-за чего Apriori строит и проверяет намного больше кандидатов на шагах 2 и 3, пересчитывая для каждого поддержку по всем 7501 транзакциям.

Эти результаты показывают обычный для частотного анализа компромисс: более низкий порог поддержки даёт более подробную картину совместных покупок (минеральная вода, макароны и яйца остаются среди самых популярных как по отдельности, так и в парах при низких порогах), но требует заметно больше вычислений из-за роста числа кандидатов. Порог стоит выбирать исходя из того, насколько детальный анализ нужен и сколько времени на него можно потратить.