

Отчёт о выполнении лабораторной работы №2 «Поиск ассоциативных правил (продолжение Apriori)»

Дисциплина: Основы интеллектуального анализа данных
Выполнил: Andrey Zamyatin, группа ET-442, ЮУрГУ

1. Формулировка задания

Доработать программу из задания «Поиск частых наборов», чтобы она также выполняла поиск ассоциативных правил. Список результирующих правил должен выдаваться в удобочитаемом виде (антецедент→консеквент) с указанием поддержки и достоверности каждого правила. Дополнительные параметры программы: порог достоверности, способ упорядочивания результирующего списка (по убыванию значения поддержки или лексикографическое).

Требуется провести эксперименты на наборе из задания 1 (baskets.csv, сведения о покупках в супермаркете). В экспериментах зафиксировать пороговое значение поддержки (например, 10%), варьировать пороговое значение достоверности (например, от 70% до 95% с шагом 5%). Выполнить визуализацию результатов в виде двух диаграмм: сравнение быстродействия поиска правил на фиксированном наборе данных при изменяемом пороге достоверности; общее количество найденных правил на фиксированном наборе данных при изменяемом пороге достоверности.

Требуется подготовить список правил, в которых антецедент и консеквент суммарно включают в себя не более семи объектов, проанализировать и изложить содержательный смысл полученного результата.

2. Репозиторий с исходными материалами

Исходный код, набор данных и остальные материалы лабораторной работы лежат в каталоге lab2 репозитория на GitHub: https://github.com/Trenj/data_mining/tree/main/lab2. Состав каталога lab2:

- association_rules_market_basket.ipynb доработка программы из работы №1, проведение экспериментов и построение графиков
- baskets.csv исходный набор данных о покупках (7501 транзакция, 115 уникальных товаров, кодировка cp1251)
- runtime_vs_confidence.png график зависимости времени поиска правил от порога достоверности
- rules_count_vs_confidence.png график зависимости числа найденных правил от порога достоверности
- Task.txt текст задания

2.1. Краткое описание реализации

Поиск частых наборов выполняется функциями из работы №1 без изменений: get_frequent_items находит частые наборы из одного товара, generate_candidates строит кандидатов следующего размера, count_support считает их поддержку по транзакциям, apriori(transactions, min_support, sort_by) связывает шаги в единый цикл и возвращает список пар (набор объектов, значение поддержки).

Поиск правил добавлен функцией generate_rules(frequent_list, min_confidence, sort_by). Для каждого частого набора длины не менее 2 она перебирает все непустые собственные подмножества в качестве антецедентов, консеквентом берет дополнение

до полного набора. Поддержка правила равна поддержке объединения антецедента и консеквента, достоверность равна отношению поддержки объединения к поддержке антецедента. В результат попадают правила с достоверностью не ниже порога. Параметр `sort_by` задает порядок вывода, как в работе №1: по убыванию поддержки или лексикографически. Каждое правило печатается в виде {антецедент} -> {консеквент} с числовыми значениями поддержки и достоверности.

2.2. Проверка работы (поддержка 2%, достоверность 30%)

При поддержке 2% алгоритм находит 104 частых набора (54 одиночных и 50 парных). Из них при достоверности 30% строится 21 правило. Ниже те же правила показаны в обоих режимах сортировки: набор правил один и тот же, различается только порядок.

По убыванию поддержки первыми идут {макароны} -> {минеральная вода} (поддержка 0.0612) и {шоколад} -> {минеральная вода} (поддержка 0.0527). При лексикографической сортировке первыми идут {блинчики} -> {минеральная вода} и {гамбургер} -> {яйца}. Полный список из 21 правила приведен в разделе 4.

3. Результаты экспериментов

Эксперименты проведены на наборе данных `baskets.csv` (7501 транзакция, 115 уникальных товаров, средняя длина транзакции 3.91 товара). Сначала зафиксирована поддержка 10% и проверены пороги достоверности от 70% до 95% с шагом 5%. Затем зафиксирована поддержка 2% и проверены пороги достоверности от 20% до 50% с шагом 5%. Для каждого порога измерено время работы и подсчитано число найденных правил.

3.1. Проверочная серия: поддержка 10%, достоверность от 70% до 95%

При поддержке 10% частыми остаются только 7 одиночных товаров (результат работы №1). Парных наборов с такой поддержкой в данных нет, поэтому строить правила не из чего. Замер это подтверждает: во всех шести точках найдено 0 правил, время генерации правил измеряется микросекундами (табл. 1).

Порог достоверности, %	Число правил	Время генерации правил, с
70	0	около 0.0000
75	0	около 0.0000
80	0	около 0.0000
85	0	около 0.0000
90	0	около 0.0000
95	0	около 0.0000

Таблица 1. Поддержка 10%: при достоверности от 70% до 95% правил нет.

3.2. Основная серия: поддержка 2%, достоверность от 20% до 50%

Чтобы получить кривые и список для разбора, поддержка зафиксирована на уровне 2%. Здесь измеряется полное время конвейера: поиск частых наборов методом Apriori плюс генерация правил (табл. 2). Число правил падает с ростом порога: от 54 при достоверности 20% до 0 при достоверности 50%. Время работы при этом почти не меняется и составляет около 0.63 с во всех точках.

Порог достоверности, %	Число правил	Время (Apriori и правила), с
20	54	0.629
25	29	0.652
30	21	0.630
35	13	0.629
40	4	0.629

Порог достоверности, %	Число правил	Время (Apriori и правила), с
45	1	0.629
50	0	0.629

Таблица 2. Поддержка 2%: число правил падает, время почти постоянно.

На рисунке 1 кривая времени почти горизонтальная. Основное время занимает поиск частых наборов, который зависит от фиксированной поддержки 2%. Фильтрация готовых наборов по порогу достоверности стоит дешево, поэтому изменение порога на общее время почти не влияет.




Рисунок 1. Время поиска правил от порога достоверности (поддержка 2%).

На рисунке 2 число правил убывает с ростом порога: 54, 29, 21, 13, 4, 1, 0 на отрезке от 20% до 50%. Спад неравномерный: основная часть правил имеет достоверность от 20% до 35%, а порог 40% и выше проходят единицы. Такое распределение обычно для разреженных корзин, где совместные покупки конкретных пар товаров встречаются редко.




Рисунок 2. Число правил от порога достоверности (поддержка 2%).

4. Анализ и выводы

Для содержательного разбора зафиксированы поддержка 2% и достоверность 30%. Получено 21 правило, это удобное количество для ручного просмотра. Все правила короткие: антецедент и консеквент суммарно дают 2 объекта, что укладывается в ограничение задания (не более семи). Список ниже отсортирован по убыванию поддержки.

№	Правило	Поддержка	Достоверность
1	{макароны} → {минеральная вода}	0.0612	0.3255
2	{шоколад} → {минеральная вода}	0.0527	0.3214
3	{молоко} → {минеральная вода}	0.0480	0.3704
4	{говяжий фарш} → {минеральная вода}	0.0409	0.4166
5	{говяжий фарш} → {макароны}	0.0403	0.4098
6	{замороженные овощи} → {минеральная вода}	0.0357	0.3748
7	{блинчики} → {минеральная вода}	0.0337	0.3548
8	{гамбургер} → {яйца}	0.0288	0.3303
9	{оливковое масло} → {минеральная вода}	0.0276	0.4190
10	{торт} → {минеральная вода}	0.0275	0.3388
11	{рис} → {минеральная вода}	0.0273	0.3596
12	{креветки} → {макароны}	0.0252	0.3526
13	{помидоры} → {минеральная вода}	0.0244	0.3567
14	{низкокалорийный йогурт} → {минеральная вода}	0.0240	0.3136
15	{оливковое масло} → {макароны}	0.0237	0.3603
16	{креветки} → {минеральная вода}	0.0236	0.3302
17	{суп} → {минеральная вода}	0.0231	0.4565
18	{курица} → {минеральная вода}	0.0228	0.3800
19	{помидоры} → {макароны}	0.0216	0.3158
20	{замороженный смузи} → {минеральная вода}	0.0203	0.3200
21	{растительное масло} → {минеральная вода}	0.0201	0.3943

Таблица 3. Правила при поддержке 2% и достоверности 30%.

В 17 правилах из 21 консеквентом выступает минеральная вода. Причина в том, что вода самый частый товар набора (поддержка 0.2384). Условная вероятность встретить воду в чеке повышена почти при любом условии, поэтому вода попадает в правую часть большинства правил. Поддержка правил лежит от 0.02 до 0.06, достоверность от 0.31 до 0.46. Это умеренные значения, которые связаны с разреженностью чеков: средняя длина транзакции меньше 4 товаров.

Наибольшую достоверность имеют правила суп → минеральная вода (0.456), оливковое масло → минеральная вода (0.419), говяжий фарш → минеральная вода (0.417), говяжий фарш → макароны (0.410). Правило говяжий фарш → макароны имеет прямой продуктовый смысл: фарш и макароны покупают вместе для горячих блюд. Похожий смысл у правил креветки → макароны (0.353), оливковое масло → макароны (0.360), помидоры → макароны (0.316): это ингредиенты пасты и соусов. Правило гамбургер → яйца (0.330) описывает совместную покупку продуктов для быстрых блюд. Такие связки подходят для совместной выкладки товаров и рекомендаций на кассе.

Пороги из примера задания (поддержка 10%, достоверность от 70% до 95%) правил не дали. Причина в данных: наибольшая достоверность парных наборов, частых при поддержке 2%, составляет около 0.46, а при поддержке 10% парных наборов нет совсем. Примерные пороги подходят для более плотных данных, а для baskets.csv рабочие диапазоны это поддержка порядка единиц процентов и достоверность от 20%

до 50%.

Программа из работы №1 доработана: добавлен поиск правил с порогом достоверности и двумя режимами сортировки, вывод оформлен в удобочитаемом виде. Эксперименты показали, что число правил падает с ростом порога достоверности (от 54 до 0 на отрезке от 20% до 50%), а время работы определяется поиском частых наборов и почти не зависит от порога. По содержанию правила описывают частоту самого популярного товара и несколько продуктовых связок, которые можно использовать в выкладке и рекомендациях.