

Отчёт о выполнении лабораторной работы №3

«Классификация с помощью дерева решений»

Дисциплина: Основы интеллектуального анализа данных

Выполнил: Andrey Zamyatin, группа ET-442, ЮУрГУ

1. Формулировка задания

Разработать программу, которая выполняет классификацию заданного набора данных с помощью дерева решений. Параметрами программы являются набор данных, критерий выбора атрибута разбиения (Information gain, Gain ratio, Gini index), а также доля, которую занимает обучающая выборка от общего размера набора данных.

Требуется провести эксперименты на наборе данных Census Income (результаты переписи населения, целевой признак — годовой доход ниже или выше \$50000): сначала использовать в качестве обучающей выборки 100% исходных данных и визуализировать построенные деревья решений; затем, фиксируя критерий выбора атрибута разбиения, варьировать соотношение мощностей обучающей и тестовой выборок от 60:40 до 90:10 с шагом 10% и вычислять показатели качества классификации: аккуратность (accuracy), точность (precision), полноту (recall) и F-меру. Результаты визуализировать в виде диаграмм: построенные деревья решений и показатели качества в зависимости от соотношения мощностей обучающей и тестовой выборок.

2. Репозиторий с исходными материалами

Исходный код, наборы данных и остальные материалы лабораторной работы лежат в каталоге lab3 репозитория на GitHub: https://github.com/Trenj/data_mining/tree/main/lab3. Состав каталога lab3:

- `decision_tree_census_income.ipynb` — реализация дерева решений, проведение экспериментов и построение графиков
- `adult.data.txt` — обучающая выборка Census Income (32561 строка)
- `adult.test.txt` — тестовая выборка (16281 строка)
- `adult.names.txt` — описание набора данных
- `tree_information_gain.png` — рисунок дерева, критерий Information gain
- `tree_gain_ratio.png` — рисунок дерева, критерий Gain ratio
- `tree_gini.png` — рисунок дерева, критерий Gini index
- `metrics_vs_split.png` — график метрик качества от доли обучающей выборки
- `task.txt` — текст задания

2.1. Краткое описание реализации

Дерево решений написано с нуля на Python + NumPy, без готовых классификаторов, так же как Apriori в работах №1-2. Класс `DecisionTree(criterion, max_depth, min_samples_split, min_gain)` строит бинарное дерево жадным рекурсивным разбиением. В каждом узле перебираются все

признаки с порогами-кандидатами: у бинарных признаков порог один, посередине отрезка, у числовых берутся квантили распределения. Лучшим считается разбиение с наибольшим значением заданного критерия. Information gain — это прирост энтропии Шеннона (подход ID3). Gain ratio делит прирост на Split info $-w_L \cdot \log_2 w_L - w_R \cdot \log_2 w_R$ (подход C4.5): так штрафуются разбиения на много мелких ветвей. Gini index — это прирост индекса Джини $1 - \sum p^2$ (подход CART). Ветвление останавливается, когда достигнута max_depth, когда объектов мало (min_samples_split), когда прирост меньше min_gain или когда узел чистый. Лист предсказывает мажоритарный класс своего подмножества.

Перед обучением выкидываем строки с неизвестными значениями «?» — как в эталонных экспериментах из adult.names.txt. Целевой признак кодируем бинарно, положительный класс — это >50K. Категориальные признаки раскрываем one-hot кодированием, всего получается 104 признака. Метрики accuracy, precision, recall и F-меру для класса >50K считаем вручную по TP/FP/FN/TN.

2.2. Проверка работы

После удаления строк с «?» в обучающей выборке осталось 30162 объекта, в тестовой — 15060. Доля класса >50K получилась 24.9% и 24.6%, один в один как в adult.names.txt (train=30162, test=15060). Для проверки обучили деревья глубины 4 всеми тремя критериями. Information gain и Gini построили полные деревья по 31 узлу, Gain ratio — 27 узлов. Корень у всех трёх одинаковый (табл. 1): признак marital-status = Married-civ-spouse с приростом информации 0.1529. Среди не состоящих в браке доход >50K только у 6.9%, а среди состоящих — у 45.5%.

Таблица 1. Корневое разбиение деревьев глубины 4 (все критерии).

Признак	Порог	Прирост	Слева n / p(>50K)	Справа n / p(>50K)
marital-status_ Married-civ-spouse	0.5	0.1529	16097 / 0.069	14065 / 0.455

3. Результаты экспериментов

Все эксперименты ниже — на наборе Census Income / Adult, положительный класс — это >50K.

3.1. Обучение на 100% данных тремя критериями

Обучили три дерева (max_depth=8, min_samples_split=50) на всех 30162 очищенных строках adult.data.txt и проверили их на независимой тестовой выборке adult.test.txt (15060 строк). Все числа собраны в табл. 2. Одно дерево обучается 2–4 секунды.

Таблица 2. Качество на adult.test.txt при обучении на 100% данных.

Критерий	Время, с	Узлы	Accuracy	Precision	Recall	F-мера
Information gain	4.3	231	0.8501	0.7069	0.6657	0.6857
Gain ratio	3.7	89	0.8376	0.7340	0.5316	0.6166
Gini index	3.9	227	0.8502	0.7120	0.6554	0.6825

Полные деревья глубины 8 содержат до 231 узла, целиком такое не разглядеть. Поэтому для рисунков обучили тем же алгоритмом деревья глубины 4: верхние уровни у них такие же, зато читается каждый узел. Левая ветвь означает, что условие выполнилось ($\leq$), правая — что нет. В узле подписаны условие, число объектов n и доля класса $>50K$. Под корнем идут разбиения по уровню образования (education-num), приросту капитала (capital-gain) и возрасту.

Decision tree: information gain (depth 4)




Рисунок 1. Дерево решений, Information gain.

Decision tree: gain ratio (depth 4)





Рисунок 2. Дерево решений, Gain ratio.

3.2. Варьирование доли обучающей выборки

Таблица 3. Метрики (Information gain) при разной доле обучающей выборки.

Доля train	Train n	Test n	Accuracy	Precision	Recall	F-мера
60%	18096	12066	0.8378	0.7675	0.5000	0.6055
70%	21112	9050	0.8433	0.7576	0.5451	0.6340
80%	24129	6033	0.8419	0.7468	0.5519	0.6348
90%	27145	3017	0.8439	0.7574	0.5486	0.6363



Information gain и Gini index показали почти одинаковое качество: accuracy 0.8501 и 0.8502, F-мера 0.6857 и 0.6825, деревья из 231 и 227 узлов. Это

сходится с литературой: в adult.names.txt для C4.5 указано 84.46%, а у нас при глубине 8 вышло около 85.0%. Gain ratio построил дерево заметно компактнее, всего 89 узлов, зато accuracy просела до 0.8376 (−1.2 п.п.), а F-мера — до 0.6166. Всё дело в нормировке на Split info. Она занижает оценку сбалансированных информативных разбиений, поэтому дерево останавливается раньше времени.

Когда доля обучающей выборки растёт с 60% до 90%, accuracy поднимается с 0.8378 до 0.8439 и дальше почти не меняется уже после 70%. Мажоритарный класс дерево схватывает быстро. Полнота растёт сильнее всего: recall поднялся с 0.5000 до 0.5486, потому что лишние данные помогают находить как раз редкий класс >50K. Точность почти стоит на месте, 0.75–0.77: чем больше данных, тем больше кандидатов в >50K находит дерево, и часть из них оказывается ложной. F-мера растёт с 0.6055 до 0.6363 без провалов, а самый большой шаг — между 60% и 70%.

Итого: accuracy 0.84–0.85 смотрится высокой, но это во многом эффект дисбаланса, ведь 75% объектов — это $\leq 50K$. У меньшего класса числа скромнее: precision около 0.75, recall 0.55–0.67. Если задача — находить людей с доходом выше \$50K, смотреть надо на recall и F-меру. Оба растут вместе с обучающей выборкой, и оба выше у Information gain и Gini index, чем у Gain ratio.